

Robótica
Informe artículo científico

Revista robótica y automatización VOL 31, No 4. diciembre 2024

Aprendizaje de modelo predictivo profundo con sesgo paramétrico
Manejo de dificultades de modelado y cambios de modelo temporales
Por: Kento Kawaharazuka, Kei Okada, Masayuki Inaba

Docente: Jaime Enrique Arango Castro

Estudiante:

Cristhian Mateo Almeida Gómez

Universidad Nacional de Colombia
Sede Manizales



1. Introducción

El artículo "Deep Predictive Model Learning With Parametric Bias" (DPM) aborda dos desafíos clave que enfrentan los robots autónomos: las dificultades en el modelado y los cambios temporales en los modelos. Estos problemas son especialmente relevantes en tareas de control y manipulación de objetos, ya que las relaciones entre el cuerpo, las herramientas y el entorno son complejas y difíciles de modelar utilizando métodos clásicos.

Modelado y Cambios Temporales:

En la robótica, es común que los robots necesiten manipular objetos en entornos cambiantes, como el control del cuerpo o la manipulación de telas. En estos casos, los métodos clásicos de modelado, que asumen relaciones estáticas, ya no son adecuados. Además, el control de un robot no solo debe considerar las relaciones actuales entre su cuerpo y las herramientas, sino que también debe adaptarse a los cambios a lo largo del tiempo, como el envejecimiento de los componentes o la variabilidad en las condiciones ambientales.

El Deep Predictive Model With Parametric Bias (DPMPB):

El modelo propuesto en el artículo, DPM, ha sido diseñado para superar estas dificultades de modelado mediante el uso de redes neuronales profundas y un sesgo paramétrico. Este enfoque tiene la capacidad de adaptarse a los cambios temporales y físicos, permitiendo que el robot se ajuste dinámicamente a su entorno y a las variaciones de su propio cuerpo.




Figura 1. Dificultades de modelo y cambios temporales del modelo

La figura 1 representa cómo un robot humanoide, como un sistema autónomo, realiza tareas complejas en entornos dinámicos. Este enfoque ayuda a resaltar la importancia del

aprendizaje predictivo en robótica y cómo los robots pueden adaptar sus modelos para mejorar su desempeño en tareas de manipulación y locomoción.

2. Deep Predictive Model with Parametric Bias (DPMPB)

El modelo predictivo profundo con sesgo paramétrico (DPMPB) es una solución avanzada diseñada para abordar las dificultades de modelado y los cambios temporales en los sistemas robóticos. Este enfoque permite modelar las relaciones entre el cuerpo de un robot, sus objetos de interés y el entorno de manera más humana e intuitiva, lo que mejora la adaptabilidad del robot al cambio dinámico de estos elementos.

Clasificación de las dificultades de modelado

La clasificación de las dificultades de modelado es esencial para comprender la aplicabilidad del DPMPB en diversos escenarios. Se identifican principalmente problemas relacionados con la relación entre el cuerpo del robot, las herramientas y los objetos que manipula. A medida que el entorno cambia, el modelo debe adaptarse a esos cambios. El DPMPB clasifica estas dificultades en tres grandes categorías:

1. Control de la base del robot: Cambios en el control de la base del robot.
2. Dinámica del cuerpo: Cambios en la dinámica de los objetos manipulados.
3. Control de equilibrio: Variaciones debido a la postura del robot y el estado del entorno, como en la manipulación de objetos.

El enfoque del DPMPB permite ajustar el modelo a estos cambios, lo que facilita su uso en aplicaciones robóticas en tiempo real, donde los cambios en los objetivos o el entorno pueden ser impredecibles.

Clasificación de los cambios temporales en los modelos

El DPMPB también maneja los cambios temporales en los modelos, donde la relación entre el cuerpo del robot y el entorno cambia con el tiempo. A medida que el robot interactúa con el entorno, su modelo debe ajustarse a estos cambios dinámicos. La clasificación de los cambios temporales se organiza en dos tipos principales de redes de transición de estado (STM) y de control (CTM):

- STM (Modelo de transición de estado): Maneja cómo el estado del robot cambia con el tiempo, considerando las variables actuales.
- CTM (Modelo de control temporal): Se enfoca en la manipulación de las variaciones en el comportamiento del robot bajo circunstancias cambiantes del entorno.

El DPMPB utiliza una combinación de STM y CTM para manejar estos cambios de manera eficiente, lo que le permite al robot adaptarse a nuevos contextos sin perder el control sobre sus movimientos y acciones.




FIGURE 2. The classification of (a) predictive models, (b) modeling difficulties, and (c) temporal model changes. The predictive models

Figura 2. Estructura del modelo

La figura 2 muestra la estructura del modelo predictivo profundo (DPM). En ella, se ilustra cómo el sistema aprende no solo de su comportamiento inmediato, sino también de los datos recogidos a lo largo del tiempo, permitiendo al robot adaptarse mejor a los cambios temporales en su entorno y cuerpo.

3. Estructura de la Red del DPMPB

El **Deep Predictive Model with Parametric Bias (DPMPB)** utiliza una arquitectura de red especializada para abordar las dificultades de modelado y los cambios en el modelo temporal en los sistemas robóticos. Consiste en dos componentes principales:

1. Arquitectura de la Red:

- La red en el DPMPB está compuesta por capas totalmente conectadas (FC), con capas de Memoria de Largo Corto Término (LSTM) añadidas para capturar las dinámicas temporales.
- La entrada a la red proviene del estado del robot y del entorno, donde s representa el estado y u es la entrada de control. La salida de la red incluye la predicción del estado actual, $y(t)$, que representa la predicción del siguiente estado del robot.

- Este modelo maneja el **comportamiento** mediante **modelado predictivo**, capturando los cambios dinámicos a lo largo del tiempo y usando **retroalimentación parametrizada** del modelo de control.

Veamos la ecuación:

$$\begin{aligned} y_{t+1} &= h(x_t, p), \\ x_t &= (s_t^T, u_t^T)^T, \\ y_{t+1} &= \begin{cases} s_{t+1} & (\text{type : STM}) \\ (s_{t+1}^T, u_{t+1}^T)^T & (\text{type : CTM}) \end{cases} \end{aligned} \quad (1)$$

Donde:

- **s** es el estado del robot (incluyendo objetos, herramientas, cuerpo, etc.).
- **u** es la entrada de control.
- **p** es el sesgo paramétrico (PB), un componente importante que permite ajustar el modelo a lo largo del tiempo mientras aprende.

2. Uso de STM y CTM:

- El modelo distingue entre **STM (Modelo de Transición de Estado)** y **CTM (Modelo de Transición de Control)**. El STM se encarga del estado actual del robot, mientras que el CTM tiene en cuenta los factores externos del entorno y los controles dinámicos. Este enfoque dual ayuda a simular con precisión la dinámica real de los sistemas robóticos.
- **STM** se utiliza típicamente para escenarios donde el estado debe cambiar según las entradas de control actuales, mientras que **CTM** integra tanto el estado actual como los factores ambientales (como la fricción, el clima, etc.).

4. Recolección de Datos y Entrenamiento del DPMPB

El entrenamiento del **DPMPB** involucra la obtención de datos de series temporales **s(t)** y **u(t)**, donde **s(t)** representa el estado del robot y el entorno, y **u(t)** es la entrada de control en cada paso temporal. Estos datos se obtienen durante las interacciones reales o simuladas para facilitar el entrenamiento del modelo.

1. Proceso de Recolección de Datos:

- **Movimiento Aleatorio:** La recolección de datos comienza con un movimiento aleatorio, lo que permite que la red recopile diversos pares de entrada-salida del sistema. Este movimiento aleatorio ayuda a explorar más efectivamente el espacio de estados.
- **Movimiento Controlado:** Una vez que el modelo ha aprendido a aproximar las dinámicas de transición, el robot comienza a usar un movimiento más controlado, guiado por la retroalimentación del sistema y el entorno.

2. Entrenamiento del DPMPB:

- Los pesos de la red se actualizan durante el proceso de entrenamiento, donde el modelo aprende de los estados y acciones previas. El modelo predictivo se ajusta para manejar comportamientos complejos como la manipulación de objetos y movimientos dinámicos.

3. Actualización del Sesgo Paramétrico (PB):

- A medida que avanza el entrenamiento, **PB** se actualiza continuamente según los datos predichos. El modelo se ajusta a los nuevos cambios, y **PB** ayuda a mitigar los problemas relacionados con los cambios temporales en las dinámicas.
- El modelo utiliza **descenso de gradiente** o técnicas similares de optimización para ajustar los parámetros y mejorar la precisión de las predicciones.⁵

5. Implementación Detallada del DPMPB

El **DPMPB** es implementado utilizando un sistema de aprendizaje profundo que utiliza **ROS** para la comunicación entre los sensores y actuadores del robot. El modelo aprende a predecir el comportamiento del robot mediante el uso de datos de entrada recolectados durante su interacción con el entorno.

1. Entrenamiento del Modelo:

- Se entrenan los datos utilizando **movimiento aleatorio** y **control guiado**, permitiendo que el robot se adapte a las condiciones cambiantes del entorno y aprenda de su propia experiencia.
- Se utilizan **LSTM (Memoria de Largo Corto Plazo)** para capturar las dinámicas temporales y ajustarlas al modelo en tiempo real.

2. Optimización del Modelo:

- El modelo predictivo es entrenado utilizando técnicas de optimización como el descenso de gradiente para minimizar la diferencia entre las predicciones y los estados reales observados.

3. Control Predictivo:

- El modelo DPMPB se utiliza para ajustar los comandos de control del robot, mejorando su capacidad para realizar tareas complejas, como navegación autónoma, manipulación de objetos y evitación de obstáculos en entornos dinámicos. Esto lo hace actualizando la salida secuencialmente, con el fin de

obtener una salida optimizada, tal que:

$$s_{seq}^{pred} = h_{expand}(s_t, u_{seq}^{opt}, p), \quad (2)$$

$$L = h_{loss}(s_{seq}^{pred}, u_{seq}^{opt}), \quad (3)$$

$$u_{seq}^{opt} \leftarrow u_{seq}^{opt} - \gamma \frac{\partial L}{\partial u_{seq}^{opt}}, \quad (4)$$

Se obtienen las variables predichas y calculadas mediante una función de pérdida.




Figura 3. Implementación detallada del DPMPB

- Aquí se muestra cómo se utilizan los componentes del sistema para entrenar la red y actualizar sus parámetros en función de los datos de entrada y salida.

6. Adaptación a Cambios en el Modelo

El DPMPB es capaz de ajustarse a **cambios en el entorno**, como se explica en la sección dedicada a la "Adaptación a cambios temporales". La red utiliza datos de entrada para actualizar su estructura y predecir cambios en el comportamiento del robot y su entorno. Esta

capacidad de adaptación es crucial en entornos dinámicos donde el comportamiento del robot puede variar significativamente.




Figura 4. Experimentación con la manipulación de objetos con la mano flexible

Esta figura muestra cómo el modelo DPMPB maneja los cambios en la manipulación de objetos dinámicos y cómo el robot se adapta a nuevos comportamientos de forma efectiva.

7. Detección de Anomalías con DPMPB

La **detección de anomalías** es otro aspecto importante del DPMPB, permitiendo identificar comportamientos inusuales que puedan indicar fallas en los sistemas del robot. La red utiliza un "Detector de Anomalías", que supervisa las predicciones de la red y genera una señal de alerta cuando se detecta un cambio significativo en el comportamiento esperado del robot.




Figura 5. Visualización de retroalimentación en robots flexibles

Se observa cómo el modelo DPMPB mejora la capacidad del robot para reconocer objetos y controlar su comportamiento mientras interactúa con un entorno dinámico.

8. Implementación en Control y Estabilidad

La red también juega un papel importante en el **control del robot**. Utilizando la información del modelo de transición de estados (STM) y control de transición (CTM), la red adapta el comportamiento del robot para cumplir con tareas de manera más eficiente. Esto incluye la **estabilidad del control** del robot cuando se enfrenta a cambios inesperados en su entorno o cuando se interactúa con objetos dinámicos.

9. Control estable de un robot con ruedas considerando cambios en el suelo

Esta sección aborda la implementación de un control estable para robots de ruedas en escenarios donde el robot debe adaptarse a cambios en el terreno. Este es un desafío clave en la robótica, ya que los robots deben operar en condiciones cambiantes, como pisos

resbaladizos o irregulares. Se describe el uso de un modelo predictivo que permite al robot ajustar su movimiento en respuesta a estos cambios, asegurando que no pierda el control.

En esta sección se resumen los resultados obtenidos a partir de los experimentos realizados con el DPMPB. El estudio demuestra que el DPMPB puede aprender modelos dinámicos entre un modelo de mano flexible y objetos, un modelo de retroalimentación visual de un cuerpo de baja rigidez, una relación probabilística entre una base con ruedas y un piso, un modelo de imitación del movimiento humano, un modelo de equilibrio de un humanoide musculoesquelético y un modelo de manipulación dinámica de tela flexible. Esto sugiere que el DPMPB no solo puede aprender las dinámicas dentro del cuerpo del robot, sino también las relaciones que este tiene con las herramientas, los objetos y el entorno.

El parámetro de bias (PB) puede integrar diferencias en objetos agarrados, configuraciones del robot, fricción del suelo, estilos de movimiento humano, zapatos y materiales de tela. El DPMPB es capaz de reconocer y adaptarse al estado actual mediante la actualización únicamente del PB, lo que permite que la predicción de la red coincida con el estado actual. Además, es posible reconocer objetos y estados que no se usaron en el entrenamiento, como dinámicas intuitivamente correctas en el espacio del PB. En el caso de control utilizando un STM, el comportamiento deseado puede lograrse construyendo una función de pérdida basada en una combinación de minimización y maximización de un valor, minimización del error con un valor objetivo y minimización del cambio desde el valor del paso anterior.

Aplicaciones del DPMPB: El DPMPB también ha demostrado que el control de estabilización para minimizar la varianza es posible mediante la introducción de una representación de media-varianza en la salida de la red neuronal. Este control no solo permite adaptarse al estado actual, sino también cambiar activamente el estilo de movimiento, dependiendo de la regla de actualización del PB en el aprendizaje por imitación. Se pueden realizar una serie de comportamientos utilizando el DPMPB, que también se espera que permita superar las dificultades de modelado y los cambios de modelos temporales.

Limitaciones

En este estudio se identificaron tres limitaciones principales. La primera es que el período de control no puede aumentarse. El período de control básico en los experimentos con STM presentados hasta ahora es de 5 Hz, lo que no es rápido. La razón de esto es que el proceso de optimización utilizando retropropagación iterativa y los métodos de descenso de gradiente en el control lleva mucho tiempo. Es importante tener en cuenta que el período de control de un CTM se puede aumentar porque el control de entrada se puede calcular solo mediante la propagación hacia adelante. Con la configuración actual de la red, la propagación hacia adelante toma unos 10 ms y la retropropagación alrededor de 40 ms.

La segunda limitación está relacionada con la capacidad de control de las tareas. Aunque las tareas manejadas en este estudio fueron exitosas, es difícil aplicar este método a tareas cuyas funciones de pérdida son más complejas y difíciles de describir por los humanos. El DPMPB debe modificarse para manejar más variables de entrada/salida abstractas.

La tercera limitación está relacionada con el tamaño del espacio de control/estado y la recolección de datos. En este estudio, principalmente se entrenaron las dinámicas que están cerca del cuerpo del robot, lo que hace que el enfoque no sea adecuado para planificadores de movimiento con estados discretos o configuraciones de tareas con grandes dimensiones de entradas de control y estados sensoriales.

Al momento de tratar con el proceso estocástico, la salida de la red es cambiada por la media y varianza de los estados, que se logran estimar mediante estimación bayesiana o iterativa.

$$P(s_{i,t}^k | D_{k,1:t-1}, W, p_k) = \frac{1}{\sqrt{2\pi\hat{v}_{i,t}}} \exp\left(-\frac{(\hat{s}_{i,t}^k - s_{i,t}^k)^2}{2\hat{v}_{i,t}}\right),$$

$$L_{\text{likelihood}}(W, p_{1:K} | D_{\text{train}}) = \prod_{k=1}^K \prod_{t=1}^{T_k} \prod_{i=1}^{N_t} P(s_{i,t}^k | D_{k,1:t-1}, W, p_k),$$

$$L_{\text{train}} = -\log(L_{\text{likelihood}}), \quad (6)$$

donde, P es la densidad de probabilidad del sensor , y nuestra media y varianza son las variables a predecir.




Figura 6. Control estable del robot de ruedas considerando un cambio en el suelo

Aquí, la figura relacionada muestra el comportamiento del robot en diversas condiciones de terreno, comparando el control con y sin ajuste dinámico en tiempo real. La prueba demuestra

cómo, al aplicar un modelo predictivo, el robot puede manejar cambios en el terreno sin perder estabilidad.

10. Manipulación de tela dinámica considerando un cambio en el material

Este apartado aborda cómo los robots pueden manipular materiales flexibles, como telas, mientras consideran cambios en sus propiedades físicas (por ejemplo, la flexibilidad de la tela). Utiliza un enfoque que implica un control preciso del robot para adaptarse a las variaciones en el material, optimizando la manipulación de objetos mientras cambian sus características.




Figura 7. Manipulación de ropa considerando un cambio material




Figura 8. Manipulación de tela.

La figura 8 ilustra el uso de un modelo predictivo de manipulación de tela con un cambio de material, mostrando cómo el robot ajusta su comportamiento al interactuar con materiales flexibles. En el gráfico se ve cómo el modelo predice los movimientos de la tela en diferentes condiciones.

11. Discusiones y limitaciones

En este estudio, se demostró que el modelo predictivo profundo con sesgo paramétrico (DPMPB) tiene la capacidad de aprender un modelo dinámico para diferentes tipos de robots, desde un modelo de retroalimentación visual de un cuerpo de baja rigidez hasta un modelo de manipulación dinámica de objetos flexibles como un robot de mano. El DPMPB no solo es capaz de modelar la dinámica interna del cuerpo del robot, sino también las relaciones entre el robot, las herramientas, los objetos y el entorno, lo que es crucial para una amplia variedad de tareas robóticas.

El uso de la Red Predictiva Paramétrica (PB) permite integrar las diferencias en la dinámica de objetos agarrados, configuraciones del robot, materiales de ropa y otros factores, permitiendo que el modelo se adapte y se actualice para que la predicción del estado del robot coincida con el estado actual. Este enfoque permite al robot reconocer objetos y situaciones que no se utilizaron en el entrenamiento, mostrando que el modelo puede generalizar dinámicas complejas.

Como aplicación práctica, el DPMPB fue utilizado para controlar de manera estable el movimiento de un robot de ruedas para minimizar la variación en el control, adaptándose no solo al estado actual del robot, sino también al estilo de movimiento, lo que permite al robot ajustarse dinámicamente a cambios en su entorno o comportamiento. Esto se logra al actualizar la PB durante el aprendizaje de imitación, lo que permite que el robot controle su movimiento de manera más precisa.

Limitaciones

Sin embargo, existen tres limitaciones principales en este estudio que deben ser consideradas:

1. **Período de Control Limitado:** El principal desafío radica en que el período de control no se puede aumentar. En los experimentos realizados con el modelo STM, el período básico de control es de 5 Hz, lo que no es suficiente para tareas que requieren una respuesta más rápida. La razón de esta limitación radica en que el proceso de optimización utilizando retropropagación iterativa y métodos de descenso de gradiente lleva tiempo. Aunque se puede incrementar el período de control para el modelo CTM, la optimización en STM requiere más tiempo debido a que el control debe ser calculado mediante propagación hacia atrás.
2. **Restricciones en las Tareas Controladas:** Las tareas en este estudio fueron exitosas dentro del rango que puede ser expresado mediante la función de pérdida. No obstante, es difícil aplicar este método a tareas más complejas donde las funciones de pérdida son más difíciles de describir y de ajustar por humanos. El DPMPB necesita modificaciones para poder manejar más variables de entrada y salida abstractas, lo que ampliaría su aplicabilidad a un mayor rango de tareas.

3. **Espacio de Estado y Recolección de Datos:** En cuanto al tamaño del espacio de estado/control y la recolección de datos, el estudio se centró en entrenar dinámicas cercanas al cuerpo del robot y de fácil manejo. Sin embargo, esto no es adecuado para planificadores de movimiento que trabajen con estados discretos o configuraciones de tarea con grandes dimensiones de entradas de control y estados sensoriales. Además, las tareas como el control de balance y la caminata requieren una mayor recolección de datos en condiciones del mundo real.

Se sugiere que para superar estas limitaciones, sería necesario mejorar la recolección de datos, la definición de primitivas, y optimizar el método de actualización de datos en tiempo real, permitiendo al robot realizar tareas continuas de manera más eficiente y en entornos más complejos.




Figura 9. Experimentación sobre el control de balance de un humanoide musculoesquelético considerando un cambio de zapatos.

12. Relación con el libro "Robotics, Vision and Control (RVCv2)":

- Este artículo se relaciona directamente con los conceptos de control adaptativo y aprendizaje autónomo tratados en RVCv2. El sesgo paramétrico propuesto es una forma de ajustar el comportamiento del robot para adaptarse mejor a condiciones cambiantes, algo que se aborda en los temas de control reactivo y aprendizaje de control en el libro.

13. Aplicaciones en la robótica autónoma:

- La capacidad de adaptación a cambios temporales y el ajuste dinámico de parámetros es crucial para el desarrollo de robots autónomos que puedan operar en entornos impredecibles. Este enfoque también podría ser útil en el campo de la navegación autónoma, donde los robots deben tomar decisiones basadas en la predicción de su entorno, ajustando su comportamiento en tiempo real.

14. Conclusiones

- El modelo DPMPB ha demostrado una notable capacidad para aprender y adaptarse a las dinámicas cambiantes en el entorno de un robot, lo que incluye la manipulación de objetos, la variabilidad en la postura del robot, y los cambios en las condiciones del entorno. Su flexibilidad para manejar dificultades de modelado y cambios temporales en las relaciones entre el cuerpo del robot, las herramientas y los objetos lo convierte en una herramienta poderosa para robots autónomos en entornos dinámicos.
- Aunque el DPMPB es efectivo en muchas tareas, las limitaciones en el período de control y la capacidad para manejar tareas de mayor complejidad siguen siendo desafíos. A pesar de que el DPMPB ofrece un modelo robusto para el control en entornos con condiciones cambiantes, es necesario optimizar los tiempos de procesamiento y mejorar la capacidad de recolección de datos en tareas con grandes dimensiones de entradas y estados sensoriales.
- El DPMPB ha demostrado su efectividad en tareas como el control de balance y la manipulación de objetos, pero aún hay un amplio margen para su mejora y expansión. A medida que se desarrollen más mecanismos de aprendizaje y se optimicen los procesos de recolección de datos, se espera que el DPMPB sea capaz de manejar tareas aún más complejas, contribuyendo significativamente al desarrollo de robots autónomos capaces de operar en entornos de alta variabilidad y complejidad.

15. Referencias

- Robotics & automation magazine, vol. 31, no. 4:
https://drive.google.com/file/d/1Nfbt8FM_WccwNAUD3P4a3SY45iPZK9bE/view